

Introducción a las OMICS, Genómica y Bases de datos especializadas



ESTEFANÍA TARIFEÑO PHD.
FACULTAD DE CS. BIOLÓGICAS



Objetivos de aprendizaje de la clase



- ☐ Conocer aspectos generales de las OMICs
- ☐ Aprender sobre la genómica
- ☐ Conocer aspectos generales de anotación de genomas

¿Como definimos OMICS?

“**OMICS**” corresponden a las ramas de la ciencia que manejan los “omas”

¿Qué son los “**OMAS**” ?


son colecciones completas de moléculas bajo estudio tales como:

GENOMAS
↓
GENOMICA

TRANSCRIPTOMAS
↓
TRANSCRIPTOMICA


PROTEOMAS
↓
PROTEOMICA
↓
METABOLOMAS
↓
METABOLOMICA

Diferentes niveles de las OMICS



GENOMAS Y GENÓMICA

- **Genoma** es el **set completo de genes** en un organismo
- **Genómica** es el **estudio del genoma completo** de un organismo (a través de WGS o Whole Genome Sequencing). Haciendo énfasis en la estructura y función de este.
- Es la primera rama de las “ómicas” en ser definida. Tomando gran importancia con la secuenciación del genoma humano que nos entregó un “**plano genético**”.
- El genoma haploide de un humano 3 billones de bases de DNA (3Gb).





La genómica nos permite

- Determinar **genomas completos** o regiones desconocidas de un genoma
- **Identificar los genes y las vías** en que estos están implicados
- Estudiar **regiones no codificantes** del genoma
- Determinar **características estructurales y regulatorias** de los genomas (Intrones, promotores, telomeros)
- Provee de **bases de datos de gran tamaño** que nos permiten realizar análisis estadísticos
- Identificar **variantes** de secuencias que puedan explicar un fenotipo en particular
- Estudiar la **evolución de organismos** y genomas


Estudios genómicos

La genómica combina metodologías de **secuenciación de DNA** y **herramientas bioinformáticas** para **secuenciar, ensamblar** y analizar la **estructura y función** de los genomas


Etapas del estudio genómico



Secuenciación de genomas



Luego del ensamble obtendremos algo como esto...



```
>gi|442618033|ref|NM_169234.2| Drosophila melanogaster hunchback (hb), tra  
variant B, mRNA
```


```
TGGTCAGTTGTGCTCCGAGTCCCGAAAACGAAAGTCGCCAGCATTGACAGGCAGCCACTGAAATACAAAA  
ATAACCAAACATCCAAAGGACGAAACGTAAGTCTGCTATCAAAACAAATATTGCCATTAAATACAATTAAAC  
TTCGTGCTTGTGCTAAAAGATAACCAATTGCAAAAAGACTTTTGTCCCGAAAACCTATTATTTTGGCAAAG  
ACCACATCCCGCACATGCGCGAATTCCGCGAAAAAGAAAGCACAAAAGCAAGCTAAAAAGCGAGGCCCAA  
AAAATAGACAAAAACGAAGAGCAAGGAGCCCCACATCGCCGCTCCCCCTCGCACGCACTGTGCGTGTG  
GTCTAACGGTAACCGTGCCGCGGTCAAGCGAGAGAGTGGGAAAGAGAGAGTCCGCGAGCGAAAAGCGAAA  
ACTTACGTGCTCCTGCTCCTGCTCCCGGTTCCCGTTTCCAAATTCTCCCGCAGAATTGCAGTTGGACTGT  
CCGCAAGCCGTCTAGAGCCGCCAAGATGCAGAACTGGGAGACGACAGCCACGACCAACTACGAGCAGCAC  
AACGCCTGGTACAACAGCATGTTTCGCGGCAAATATCAAACAGGAGCCAGGTCATCATCTCGACGGGAATA  
GCGTGGCCAGCAGTCCGCGCCAATCGCCCATTCCCTCGACCAATCACCTGGAACAGTTTCTCAAGCAGCA  
GCAGCAGCAGCTTCAGCAGCAACCCATGGATACCCCTGTGCGCCATGACCCCATCACCCAGCCAAAACGAT  
CAAAACAGCCTGCAGCATTACGATGCTAAGTTCGAGCAACAGTTGCTGCAGCAACAGCAGTACCAGCAGC  
ATTTCCAGGCAGCCAGCAGCAACATCATCACCATCACCATCTGATGGGTGGATTCAATCCGCTGACGCC  
ACCTGGTCTGCCCAATCCCATGCAGCACTTCTATGGCGGCAATCTGCGACCCAGTCCGCGAGCCACGCCC  
ACATCTGCCTCCACAATTGCGCCCCGTTGCAGTTGCCACTGGCAGCAGCGAGAAGTTGCAGGCACTAACAC  
CACCCATGGATGTACACCCGCCAAGTCGCGCGGCCAAGTCGAGTCAGTCGAATATTGAGCCGGAGAAGGA  
GCACGATCAGATGTGAACTCCAGCGAGGACATGAAGTACATGGCCGAGTCCGAGGACGATGATACCAAC  
ATCCGGATGCCCATCTACAATTGCGACGGCAAGATGAAGAACTACAAGTGAAGACCTGCGGCGTGGTGG  
CCATCACCAAGGTGGACTTCTGGGCGCACACCCGACCCACATGAAACCAGACAAGATCCTGCAGTGCCC  
GAAGTGCCCGTTTCGTCACCGAGTTCAAGCACCCTTGGAGTACCATATCCGGAAGCACAAGAACCAAAAG  
CCCTTCCAGTGCGACAAATGCAGCTACACGTGTGTCAACAAATCCATGCTAAACTCGCACCGCAAGTCGC  
ACAGTTCTGTGTATCAGTACCGTTGTGCGGATTGTGATTACGCCACCAAGTATTGCCACAGCTTCAAGCT  
GCATCTGCGCAAGTATGGTCAAGCCCCGGCATGGTTTTGGACGAGGATGGCACCCCGAATCCCTCGTTG  
GTCATCGATGTTTACGGCACGCGTCGTGGTCCGAAGAGCAAGAATGGTGGACCGATTGCCAGTGGAGGAA  
GTGGCAGCGGCAGCCGGAAGTCAAATGTTGCAGCTGTGCTCCGCGCAACAGCAATCTCAGCCAGCTCA  
GCCAGTCGCCACATCTCAGCTGAGTGCCGCCCTGCAAGGATTCCCTCTGGTTCAAGGCAACTCCGCTCCT  
CCGGCGGCATCTCAGTGCTCCCGCTGCCCGCCTCTCCTGCCAAGAGTGTGGCCAGTGTGGAACAGACGC  
CCAGCTTGCCAGTCCAGCCAATCTTCTGCCTCCTCTGGCCAGCCTTCTGCAGCAGAACCGBAACATGGC  
CTTCTTCCCCTACTGGAACCTCAATCTCCAGATGCTGGCGGCCAACAAACAGGCCGCTGTCTGGCCCAA
```

Anotación del genoma: Predicción de genes y vías

La anotación del genoma permite **encontrar las características biológicas** más relevantes en una secuencia genómica sin caracterizar

¿Porque anotar genomas?


- Secuencias sin caracterizar no son útiles para los estudios biológicos
- Toman sentido al encontrar elementos tales como marcadores, genes, mRNAs, secuencias de proteínas



Anotación del genoma: Predicción de genes y vías


Dos maneras de realizar la anotación

Automática



Generada de manera computacional
Rápida
Barata
Puede no ser tan precisa
Constantemente actualizada

Manual



**Generada por un científicx entrenadx
que interpreta la información**
Lenta
Cara
Bastante precisa
No tan actualizada

Anotación del genoma realizado en dos pasos

1) Anotación estructural / predicción de genes

¿Dónde están los genes?

Definición de “gene models” en una secuencia genómica a través de la definición del patrón de **Exones e Intrones**

Aproximaciones

Experimental

En base a datos ESTs, cDNAs, RNA-seq

Predictiva

ab initio: identificación de elementos (intrínseco)
Comparativo (extrínseco)

2) Anotación funcional

¿Cuál es la función de ese transcrito codificado?

Define la función biológica de los “gene models”. Se define en **base a la información pre-existente** de genes (búsqueda por homología)

Aproximaciones

Nombre del producto del gene

Símbolo


EC number

Perfil de expresión

Ontología

Otras características funcionales relevantes

Intrinsic information



Extrinsic information


Genoma de referencia

Corresponde a la versión ensamblada del genoma y su set de genes de un **individuo idealizado** de una especie determinada. Este no representa el genoma de un individuo, sino que es un mosaico resultado de diferentes dadores de DNA.

Re-sequencing: Es una nueva secuenciación del genoma de un individuo para identificar diferencias entre este individuo y el genoma de referencia.

Genomas completos secuenciados a la fecha

Número de proyectos públicos a la fecha



Organisms

Organisms [312,788](#)

Archaea [2,923](#)

Bacteria [276,009](#)

Eukarya [24,880](#)

Viruses [8,937](#)

Bacterial Type Strains [15,557](#)

Archaeal Type Strains [561](#)

Bases de datos de acceso público (BD Primaria)

NCBI genome:

<https://www.ncbi.nlm.nih.gov/genome>

Genomas Online Database (GOLD):


<https://gold.jgi.doe.gov/>

Integrated microbial genome & microbiomes (IMG):

<https://img.jgi.doe.gov/>

Recursos Genómicos de disponibilidad pública (“BD secundaria”)

- Integran los genomas de referencia con información funcional de diversas fuentes. Proporcionando una interface gráfica que facilita la navegación, búsqueda, recuperación y análisis eficiente de la data genómica.



NCBI Map Viewer
<http://www.ncbi.nlm.nih.gov/Genomes/>

Genomas de referencia: Ensembl (<http://www.ensembl.org/index.html>)

- Es un genome browser para genomas vertebrados que apoya la investigación en áreas como la genómica comparativa, evolución, variación de secuencias y regulación transcripcional

Tools

[All tools](#)

BioMart >

Export custom datasets from Ensembl with this data-mining tool

BLAST/BLAT >

Search our genomes for your DNA or protein sequence

Variant Effect Predictor >

Analyse your own variants and predict the functional consequences of known and unknown variants

Search

All species ▼ for

Go

e.g. BRCA2 or rat 5:62797383-63627669 or rs699 or coronary heart disease

All genomes

-- Select a species -- ▼

- [View full list of all Ensembl species](#)
- [Edit your favourites](#)

Favourite genomes



Human
GRCh38.p12

[Still using GRCh37?](#)



Mouse
GRCm38.p6



Zebrafish
GRCz11

Ensembl is a genome browser for vertebrate genomes that supports research in comparative genomics, evolution, sequence variation and transcriptional regulation. Ensembl annotate genes, computes multiple alignments, predicts regulatory function and collects disease data. Ensembl tools include BLAST, BLAT, BioMart and the Variant Effect Predictor (VEP) for all supported species.

Ensembl Release 92 (April 2018)

- [New goat annotation on the ARS1 assembly](#)
- [Update of Marmoset assembly and genebuild](#)
- [Mouse: update to Ensembl-Havana GENCODE gene set](#)
- [Update to Ensembl-Havana human GENCODE gene set \(release 28\)](#)
- [New command line tool for LD](#)

[Full details](#) | [All web updates, by release](#) | [More news on our blog](#)

- 07 Jun 2018: [Update to Perl and BioPerl in Ensembl](#)
- 05 Jun 2018: [Gene Variant Image retirement for human, e93](#)
- 01 Jun 2018: [Training in low-middle income countries](#)

[Go to Ensembl blog](#)


Compare genes across species



Find SNPs and other variants for my gene

GTATACATTC
CTTAAAGTCTT
CTTCTAATTCT
GTAACATTTCC

Gene expression in different tissues




Retrieve gene sequence

GCCTGACTTCGGGTGG
GGGCTTGTGGGCGAGC
GGGCTTGTGTGGGCGAGC
AGGGGACAGATTGTGA
CACTCTGGAGCGGCTT
CCCACTCCAGCGTGGC

Find a Data Display




Use my own data in Ensembl



Estadísticas del genoma humano (Ensembl)

Assembly	GRCh38.p13 (Genome Reference Consortium Human Build 38), INSDC Assembly GCA_000001405.28 , Dec 2013
Base Pairs	4,537,931,177
Golden Path Length	3,096,649,726
Annotation provider	Ensembl
Annotation method	Full genebuild
Genebuild started	Jan 2014
Genebuild released	Jul 2014
Genebuild last updated/patched	Mar 2020
Database version	101.38
Gencode version	GENCODE 35



Gene counts (Primary assembly)

Coding genes	20,440 (incl 633 readthrough)
Non coding genes	23,995
Small non coding genes	4,867
Long non coding genes	16,907 (incl 306 readthrough)
Misc non coding genes	2,221
Pseudogenes	15,222 (incl 6 readthrough)
Gene transcripts	229,649

????????????????

Gene counts (Alternative sequence)

Coding genes	3,048 (incl 41 readthrough)
Non coding genes	1,556
Small non coding genes	297
Long non coding genes	1,072 (incl 45 readthrough)
Misc non coding genes	187
Pseudogenes	1,798
Gene transcripts	21,659

Ensamble primario: Representa la colección de cromosomas ensamblados, secuencias no localizadas o no posicionadas, que, en combinación, representa un genoma haploide no redundante.

Secuencias alternativas: corresponden a representaciones alternativas de un locus encontradas en un ensamble haploide (ei. Haplotipos). No representan cromosomas completos.

Genomas de referencia: NCBI Genomes (<https://www.ncbi.nlm.nih.gov/genome>)

Genome

Genome ▼

salmo salar[orgn]



Search

[Create alert](#) [Limits](#) [Advanced](#)

[Help](#)

Salmo salar (Atlantic salmon)

Representative genome: [Salmo salar \(assembly ICSASG_v2\)](#)

Download sequences in FASTA format for [genome](#), [transcript](#), [protein](#)

Download genome annotation in [GFF](#), [GenBank](#) or [tabular](#) format

BLAST against Salmo salar [genome](#)

NCBI Resources

[Genome Data Viewer](#)

Tools

[BLAST Genome](#)

ID: 369

Related information

[Assembly](#)

[BioProject](#)

[Gene](#)

[Components](#)

[Protein](#)

[PubMed](#)

[Taxonomy](#)

Search details

"Salmo salar"[Organism]

Display Settings: [Overview](#)

Send to: ▼

[Organism Overview](#) ; [Organelle Annotation Report \[1\]](#)



Salmo salar (Atlantic salmon)

Atlantic salmon; highly valued in fishing and aquaculture

Lineage: [Eukaryota\[3275\]](#); [Metazoa\[1073\]](#); [Chordata\[524\]](#); [Craniata\[514\]](#); [Vertebrata\[514\]](#); [Euteleostomi\[506\]](#); [Actinopterygii\[174\]](#); [Neopterygii\[174\]](#); [Teleostei\[173\]](#); [Protacanthopterygii\[7\]](#); [Salmoniformes\[6\]](#); [Salmonidae\[6\]](#); [Salmoninae\[6\]](#); [Salmo\[1\]](#); [Salmo salar\[1\]](#)

The Atlantic salmon *Salmo salar* is a highly valued food fish. Salmonid ancestors had a tetraploid genome, and it is thought that these fish are still re-establishing diploidy. As a result, a given locus in one species may have merged into a single gene, while in another species two paralogs may still exist. Triploid salmon, found in natural populations [More...](#)

Summary

Submitter: International Cooperation to Sequence the Atlantic Salmon Genome
Assembly level: Chromosome
Environment: OxygenReq:Aerobic, Habitat:Aquatic
Assembly: GCA_000233375.4 ICSASG_v2 **scaffolds:** 241,573 **contigs:** 368,060 **N50:** 57,618 **L50:** 9,869
BioProjects: PRJNA287919, PRJNA72713
Whole Genome Shotgun (WGS): INSDC: AGKD000000000.4
Statistics: total length (Mb): 2966.89
protein count: 97738

Genomas de referencia: UCSC Genome Browser (<https://genome.ucsc.edu/>)



Our tools

- **Genome Browser**
interactively visualize genomic data
- **BLAT**
rapidly align sequences to the genome
- **Table Browser**
download data from the Genome Browser database
- **Variant Annotation Integrator**
get functional effect predictions for variant calls
- **Data Integrator**
combine data sources from the Genome Browser database
- **Gene Sorter**
find genes that are similar by expression and other metrics
- **Genome Browser in a Box (GBiB)**
run the Genome Browser on your laptop or server
- **In-Silico PCR**
rapidly align PCR primer pairs to the genome
- **LiftOver**
convert genome coordinates between assemblies
- **VisiGene**
interactively view in situ images of mouse and frog

[More tools...](#)

Our story

On June 22, 2000, UCSC and the other members of the International Human Genome Project consortium completed the first working draft of the human genome assembly, forever


What's new

Aug. 10, 2018 - [New interact track type](#)

Jul. 31, 2018 - [New Ensembl gene tracks for 60 assemblies](#)

En resumen...

Set completo de genes = Genoma



Genoma de referencia

1. Secuenciación

High-throughput Sequencing

2. Ensamble

Solapamiento de secuencias

3. Anotación

Estructural y Funcional (manual o automática)

4. Publicar secuencias

Repositorios públicos y Recursos genómicos